

# Modelos de Clasificación / Variable Dependiente Cualitativa

## Métodos Cuantitativos en Estudios Urbanos II - MEU UTDT

Ricardo Pasquini

2 de julio de 2025

# Modelos de Clasificación

- ▶ Hasta aquí hemos trabajado con variables continuas como variables a explicar/predecir, pero en una gran cantidad de aplicaciones las predicciones son discretas.
- ▶ Estos modelos también son conocidos como modelos de clasificación

# Modelos de Clasificación Binaria

- ▶ Ejemplo: Elección de transporte
- ▶ Variable objetivo: 1 si toma transporte público, 0 de otro modo.

$$P(\text{Transporte Publico}) = \beta_0 + \beta_1 \text{Ingreso}_i + \beta_2 \text{Genero}_i + \epsilon_i$$

# Modelos de Clasificación Binaria

- ▶ En general la variable  $y_i \in \{0, 1\}$ , representando un resultado "Sí/ "No".
- ▶ El objetivo es describir  $P(y_i = 1|x_i)$  (Notar que esto determinaría la completa distribución condicional)
- ▶ Si proponemos un modelo lineal:


$$P(y_i = 1|x_i) = x_i' \beta$$

- ▶ Notemos también que  $P(y_i = 1|x_i) = E(Y_i|x_i)$  por lo tanto podríamos estimar

$$y_i = x_i' \beta + e_i$$


## Modelos de Clasificación Binaria

- Sin embargo, notemos que en un caso de observaciones binarias tendríamos algo como:



# Modelo Lineal para Clasificación

- El resultado devolvería:



# Modelos de Clasificación

- ▶ Es deseable imponer una restricción adicional, que  $0 \leq P(y_i = 1|x_i) \leq 1$
- ▶ Por eso la alternativa estándar es proponer un modelo como:


$$y_i = F(x'_i\beta) + e_i$$

donde  $F(\cdot)$  es una función que cumple la restricción, como por ejemplo una Función de Densidad Acumulativa.

- ▶ Dos funciones comúnmente utilizadas son:
  - ▶ Logística:  $F(u) = \frac{1}{(1+e^{-u})} = \frac{e^u}{1+e^u}$  (resultando en el modelo llamado **Logit**)
  - ▶ Normal:  $F(u) = \Phi(u)$  (resultando en el modelo llamado **Probit**)

## Ejemplo: Logit

$$\left\{ \begin{array}{l} P(Z) = \frac{1}{1 + e^{-Z}} \\ Z = \alpha + \beta X_i \end{array} \right.$$





# Logit

- ▶ Logit también es el nombre que toma el logaritmo del ratio de chances entre dos resultados.
- ▶ En este caso, tal como fue definido, el modelo logit propone que el logaritmo del ratio de chances es la función lineal  $\alpha + \beta X$ . Esto se puede ver facilmente:


$$\ln \frac{P(y_i = 1|x_i)}{P(y_i = 0|x_i)} = \beta X$$

## Efectos marginales

- ▶ Comúnmente nos interesará conocer  $\frac{\partial p}{\partial x}$ .
- ▶ Notar que debido a la transformación funcional de  $F(\cdot)$  el efecto marginal de un incremento en  $x_i$  no es constante. Por lo tanto, para conocer el efecto de un incremento marginal en  $x$  adicionalmente tendremos que especificar el nivel (de  $Z$ ) de interés.

$$\left\{ \begin{array}{l} P(Z) = \frac{1}{1 + e^{-Z}} \\ Z = \alpha + \beta X_i \end{array} \right.$$

$$\frac{\partial p}{\partial x} = \frac{e^{-Z}}{(1 + e^{-Z})^2} \beta$$



# Efectos marginales

- ▶ Típicamente los paquetes estadísticos devuelven un efecto marginal que:
  - ▶ Podría estar calculado por default en el *valor promedio de las variables* (esto podría ser de interés o no).
  - ▶ Nos permiten determinar los valores de las variables explicativas donde calcular el efecto.
  - ▶ Permiten calcular un *Efecto Marginal Promedio* entendido como el promedio de los efectos marginales en los valores definidos por las observaciones en nuestra muestra.

# Estimación

- ▶ La estimación se realiza mediante Máxima Verosimilitud.
- ▶ Recordemos que la estimación mediante Máxima Verosimilitud propone buscar el valor del parámetro que maximiza la probabilidad conjunta de ocurrencia de los datos que sugieron en la muestra.

$$\max_{\beta} \prod_{i=1}^n P(Y_i, \beta)$$

donde  $p(Y_i, \beta)$  es la probabilidad de la observación i-esima en cuestión.

- ▶ Notemos en este caso las probabilidades son

$$\begin{cases} P(Y = 0|X) & \text{si } Y_i = 0 \\ P(Y = 1|X) & \text{si } Y_i = 1 \end{cases}$$

# Estimación

- ▶ Es decir los términos de la productoria serán

$$\begin{cases} 1 - F(x_i' \beta) & \text{si } Y_i = 0 \\ F(x_i' \beta) & \text{si } Y_i = 1 \end{cases}$$

- ▶ Siguiendo el método de máxima verosimilitud, será conveniente maximizar la función en logaritmos

$$\max_{\beta} L = \ln\left(\prod_{i=1}^n P(Y_i, \beta)\right) = \max_{\beta} \sum \ln(P(Y_i, \beta))$$

- ▶ Típicamente se utilizarán algoritmos de maximización para encontrar el máximo.

# Multinomial Logit para elecciones múltiples

- ▶ Un caso de interés es la elección entre alternativas múltiples. Por ejemplo:
  - ▶ Elección medio de transporte (auto, colectivo, tren, etc.).
  - ▶ Elección residencial (barrio 1, barrio 2,...,barrio n).
- ▶ Analizaremos aquí un modelo con alternativas que no tienen un orden implícito. Para alternativas ordenadas, existen otros modelos disponibles.

## Multinomial Logit para elecciones múltiples

- El modelo multinomial se puede fundamentar suponiendo que cada individuo tiene una utilidad por la  $j$ -ésima opción dada por

$$U_{ij} = \beta' z_{ij} + \epsilon_{i,j}$$

- Si el consumidor elige la  $j$ -ésima opción sobre las  $J - 1$  restantes, es porque esa opción le dió mayor utilidad. La idea de la modelización probabilística es

$$P(Y_i = j) = P(U_{ij} > U_{ik}) \quad \forall k \neq j$$

- Y se puede obtener que la probabilidad de elegir la categoría  $j$ -ésima es:

$$P(Y_i = j) = \frac{e^{\beta' z_{ij}}}{\sum_{j=1}^J e^{\beta' z_{ij}}}$$

## Multinomial Logit para elecciones múltiples

- ▶ Un supuesto implícito del modelo es la independencia de alternativas irrelevantes.
- ▶ Este supuesto pide que la preferencia por una categoría sobre otra no cambie si se considera una tercera como parte de la comparación.
- ▶ El uso de este supuesto permite que este modelo pueda implementarse como la comparación de  $K-1$  categorías contra una  $K$ -ésima. Conociendo estas preferencias puedo derivar todas las demás.



## Derivación como un conjunto de elecciones binarias

$$\ln \frac{Pr(Y_i = 1)}{Pr(Y_i = K)} = \beta_1 \cdot X_i$$

$$\ln \frac{Pr(Y_i = 2)}{Pr(Y_i = K)} = \beta_2 \cdot X_i$$

$\vdots$

$$\ln \frac{Pr(Y_i = K - 1)}{Pr(Y_i = K)} = \beta_{K-1} \cdot X_i$$

## Multinomial Logit para elecciones múltiples

$$Pr(Y_i = 1) = Pr(Y_i = K)e^{\beta_1 \cdot X_i}$$

$$Pr(Y_i = 2) = Pr(Y_i = K)e^{\beta_2 \cdot X_i}$$

$$\vdots$$

$$Pr(Y_i = K - 1) = Pr(Y_i = K)e^{\beta_{K-1} \cdot X_i}$$

$$Pr(Y_i = K) = 1 - Pr(Y_i = K) \sum_{k=1}^{K-1} e^{\beta_k \cdot X_i}$$

$$\rightarrow Pr(Y_i = K) = \frac{1}{1 + \sum_{k=1}^{K-1} e^{\beta_k \cdot X_i}}$$

## Multinomial Logit para elecciones múltiples

Reemplazando para obtener expresiones para  $Pr(Y_i = 1)$ ,  $Pr(Y_i = 2)$  ...

$$Pr(Y_i = 1) = \frac{e^{\beta_1 \cdot X_i}}{1 + \sum_{k=1}^{K-1} e^{\beta_k \cdot X_i}}$$

$$Pr(Y_i = 2) = \frac{e^{\beta_2 \cdot X_i}}{1 + \sum_{k=1}^{K-1} e^{\beta_k \cdot X_i}}$$

$$\vdots$$

$$Pr(Y_i = k) = \frac{e^{\beta_k \cdot X_i}}{1 + \sum_{k=1}^{K-1} e^{\beta_k \cdot X_i}}$$

# Estimación

- ▶ Como en el caso del Logit, se aplicará un método similar a Máxima Verosimilitud para identificar las condiciones del óptimo, y se utilizarán algoritmos numéricos iterativos para encontrar la solución.

# Resumen

- ▶ Los modelos de clasificación binaria incorporan una transformación no-lineal que garantizar que las predicciones vivan en el rango apropiado.
- ▶ Esto implica que los efectos marginales de un factor explicativo serán específicos a un nivel deseado.
- ▶ El modelo puede generalizarse

## Referencias

- ▶ Hansen, B. 2018, Econometrics , ch. 21
- ▶ Greene Análisis Econométrico ch.19