

# Revisión de Supuestos Estadísticos e Introducción a Análisis Espacial

Métodos Cuantitativos en Estudios Urbanos II - MEU UTDT

Ricardo Pasquini

22 de julio de 2026

## Repaso

- ▶ Estadístico T es la base del Test de Hipótesis

$$t = \frac{\hat{\beta} - \beta_0}{SE(\hat{\beta})} = \frac{\hat{\beta} - \beta_0}{\sqrt{\hat{\sigma}^2(X'X)^{-1}}}$$

Donde:

- ▶  $\hat{\beta}$  es el coeficiente estimado
  - ▶  $\beta_0$  es el valor bajo la hipótesis nula
  - ▶  $SE(\hat{\beta})$  es el error estándar del coeficiente
  - ▶  $\hat{\sigma}^2$  es la varianza estimada de los errores
- ▶ Este estadístico tiene una distribución T-student. Sin embargo, este resultado se construye sobre varios supuestos:
    - ▶ Los errores tienen una varianza constante
    - ▶ Los errores son independientes
    - ▶ Los errores tienen una distribución Normal

# Heteroscedasticidad

- ▶ Varianza no constante en los errores del modelo  
En el modelo homoscedástico (ideal):



$$Var(\epsilon_i) = \sigma^2 \text{ para todo } i$$

En presencia de heteroscedasticidad:

$$Var(\epsilon_i) = \sigma_i^2 \text{ varía con } i$$

- ▶ La dispersión de los residuos varía según los valores de X o Y
- ▶ Puede surgir por:
  - ▶ Datos agrupados con diferentes niveles de variabilidad
  - ▶ Relaciones no lineales subyacentes
  - ▶ Errores de medición que varían con la magnitud de las variables

# Heteroscedasticidad - Visualización



**Figura:** Residuos vs. Valores Ajustados: Homoscedástico (izq.) vs. Heteroscedástico (der.)

# Consecuencias de la Heteroscedasticidad

- ▶ Estimadores OLS siguen siendo insesgados
- ▶ Errores estándar incorrectos
- ▶ Intuición del problema:
  - ▶ En OLS, asumimos que cada observación tiene la misma varianza ( $\sigma^2$ )
  - ▶ Cuando hay heteroscedasticidad, algunas observaciones son más ruidosas" que otras
  - ▶ La fórmula tradicional del error estándar:

$$SE(\hat{\beta}) = \sqrt{\hat{\sigma}^2 (X'X)^{-1}}$$

asume incorrectamente que todas las observaciones tienen el mismo peso

- ▶ En realidad, deberíamos dar:
  - ▶ Menor peso a observaciones con alta varianza
  - ▶ Mayor peso a observaciones con baja varianza

# Soluciones para la Heteroscedasticidad

- ▶ Uso de errores estándar robustos (HC0 - White)
  - ▶ En Python (statsmodels):

```
import statsmodels.formula.api as smf
model = smf.ols('precio ~ superficie + habitaciones', data=df)
results = model.fit(cov_type='HC0')
```
  - ▶ En R:

```
coeftest(model, vcov = vcovHC(model, type = "HC0"))
```
- ▶ Otras correcciones de errores estándar robustos:
  - ▶ HC1: Corrección adicional para muestras pequeñas
  - ▶ HC2: Considera el leverage de las observaciones (el leverage es una medida de la importancia de la observación particular en el fit del modelo)
  - ▶ HC3: Más conservador, mejor para muestras muy pequeñas

## Soluciones para la Heteroscedasticidad (cont.)

- ▶ Transformación de variables:
  - ▶ Transformación logarítmica cuando la varianza aumenta con el nivel
- ▶ Modelado explícito de la varianza:
  - ▶ Mínimos Cuadrados Ponderados (WLS)
  - ▶ Se asignan pesos inversamente proporcionales a la varianza estimada
  - ▶ Requiere conocer o poder modelar la estructura de la varianza

# Normalidad de los Residuos




Figura: Distribución de Residuos: Normal vs. Sesgada



# Normalidad de los Residuos - Q-Q Plot




Figura: Q-Q Plots: Residuos Normales vs. Sesgados

## Consecuencias e Importancia de la No-Normalidad

- ▶ Menos crucial cuando  $n$  es grande (Teorema asintótica)
- ▶ Las pruebas  $t$  y  $F$  son robustas con muestras grandes
- ▶ Mayor preocupación en muestras pequeñas
- ▶ Soluciones:
  - ▶ Transformaciones de la variable dependiente
    - ▶ Logarítmica
    - ▶ Raíz cuadrada
  - ▶ Identificar y tratar valores atípicos

# Independencia de las Observaciones

- ▶ Tipos de Autocorrelación:


- ▶ Temporal

- ▶ Común en series de tiempo
    - ▶ Patrones sistemáticos en el tiempo
    - ▶ Observaciones cercanas en el tiempo están relacionadas

- ▶ Espacial

- ▶ Frecuente en estudios urbanos
    - ▶ "Todo está relacionado con todo, pero las cosas cercanas están más relacionadas entre sí"
    - ▶ Dependencia basada en la ubicación geográfica

# Autocorrelación Temporal



**Figura:** Comparación: Residuos con Autocorrelación Temporal (izq.) vs. Residuos Independientes (der.)

# Autocorrelación Espacial




Figura: Residuos con Autocorrelación Espacial vs. Aleatorios

# Análisis de Autocorrelación Espacial




Figura: Diagramas de Moran: Patrón Espacial vs. Aleatorio

# Consecuencias de la Autocorrelación

- ▶ Estimadores OLS ineficientes
- ▶ Errores estándar sesgados: cuando hay autocorrelación positiva, los errores estándar son menores que los reales (llevando a sobre-detectar significancia). Cuando hay autocorrelación negativa, los errores estándar son mayores que los reales (llevando a que no se detecte la significancia).
- ▶ Inferencia estadística no válida
- ▶ Predicciones subóptimas
- ▶ Soluciones:
  - ▶ Modelos con rezagos temporales (AR, MA, ARIMA)
  - ▶ Modelos espaciales
    - ▶ Rezago espacial (Spatial Lag)
    - ▶ Error espacial (Spatial Error)
    - ▶ Modelos mixtos espaciales
  - ▶ Corrección de errores estándar por clusters

# Análisis Espacial

- ▶ ¿Qué hace que un análisis sea espacial?
  - ▶ Tanto la ubicación como los atributos importan
  - ▶ Los resultados cambian cuando cambia la disposición espacial
  - ▶ Contrasta con el análisis no espacial donde la ubicación es irrelevante
- ▶ Dimensiones de la econometría espacial:
  - ▶ Especificar la estructura de la dependencia espacial
  - ▶ Testear su presencia
  - ▶ Estimar modelos con efectos espaciales
  - ▶ Precaución: Los efectos espaciales podrían no cambiar las conclusiones



# Desafíos Clave en el Análisis Espacial

- ▶ Falacia Ecológica
  - ▶ No se puede inferir comportamiento individual de datos agregados
  - ▶ Se debe mantener el nivel apropiado de interpretación
- ▶ Problema de la Unidad de Área Modificable (MAUP)
  - ▶ Los resultados dependen de la escala de agregación
  - ▶ Los resultados dependen de la zonificación/agrupación de unidades
  - ▶ Ejemplo: Distritos electorales y gerrymandering
- ▶ Problema de Cambio de Soporte
  - ▶ Mezcla de datos de diferentes escalas espaciales
  - ▶ Ejemplo: Datos puntuales vs. datos de área
  - ▶ Soluciones: agregar a una escala común, interpolar

# Matriz de Pesos Espaciales (W)

- ▶ Propósito: Formaliza las relaciones espaciales entre observaciones
- ▶ Características:
  - ▶ Matriz  $N \times N$  ( $N$  = número de observaciones)
- ▶ Mayormente dispersa ( 99 % *cerostpicamente*)  $Elementos diagonales = 0$  ( *sin auto – vecinos* )
- ▶ Tipos Comunes:
  - ▶ Basados en Contigüidad
    - ▶ Rook (bordes comunes)
    - ▶ Queen (bordes + esquinas)
    - ▶ Bishop (solo esquinas)
  - ▶ Basados en Distancia
    - ▶ Bandas de distancia
    - ▶ K vecinos más cercanos
    - ▶ Funciones de distancia

# Estadístico I de Moran

- ▶ Fórmula:

$$I = \frac{N}{W} \frac{\sum_i \sum_j z_i z_j \cdot w_{i,j}}{\sum_i z_i^2}$$

donde:

- ▶  $z_i = y_i - \bar{y}$  (desviación de la media)
  - ▶ N es el número de unidades espaciales
  - ▶ W es la suma de pesos
- ▶ Limitaciones:
    - ▶ Funciona como estadístico de mala especificación
    - ▶ Detecta correlación espacial, pero también:
      - ▶ Heteroscedasticidad
      - ▶ No linealidad

# Introducción a la Regresión Espacial

- ▶ Desafío clave:
  - ▶ No se pueden modelar todas las interacciones con datos de corte transversal
  - ▶ N observaciones pero  $N^2$  interacciones potenciales
  - ▶ Solución: Simplificar usando matriz de pesos espaciales

# Variables Espacialmente Rezagadas

- ▶ Concepto básico: Promedio ponderado de observaciones vecinas
- ▶ Características:
  - ▶ Similar al rezago distribuido en series de tiempo
  - ▶ Suaviza la variabilidad (menor varianza)
  - ▶ Excluye auto-vecinos (diagonal de  $W$  es cero)

# Modelo de Rezago Espacial

- ▶ Incluye la variable dependiente espacialmente rezagada ( $Wy$ )
- ▶ Forma básica:

$$y = \rho Wy + X\beta + \epsilon$$

donde:

- ▶  $\rho$  es el coeficiente de autocorrelación espacial
  - ▶  $Wy$  es el rezago espacial de la variable dependiente
  - ▶  $X\beta$  son las variables explicativas y sus coeficientes
- ▶ Características:
  - ▶ Modela interacción espacial directa
  - ▶ Tiene efectos multiplicadores (bucles de retroalimentación)
  - ▶ Su omisión lleva a sesgo e ineficiencia